Pipeline ETL para el Análisis de Ventas de SuperMart Colombia

Isabella Naranjo, Nicolas Varon, Nicole Daza

Universidad de La Sabana

Information Systems S2G4

Ing. Javier Daza

16 de octubre de 2026

Resumen Ejecutivo

El presente reporte presenta los resultados del pipeline ETL desarrollado para SuperMart Colombia. El sistema integró, limpió, validó y transformó datos de ventas provenientes de múltiples fuentes CSV, generando un conjunto de datos analítico confiable para la toma de decisiones comerciales.

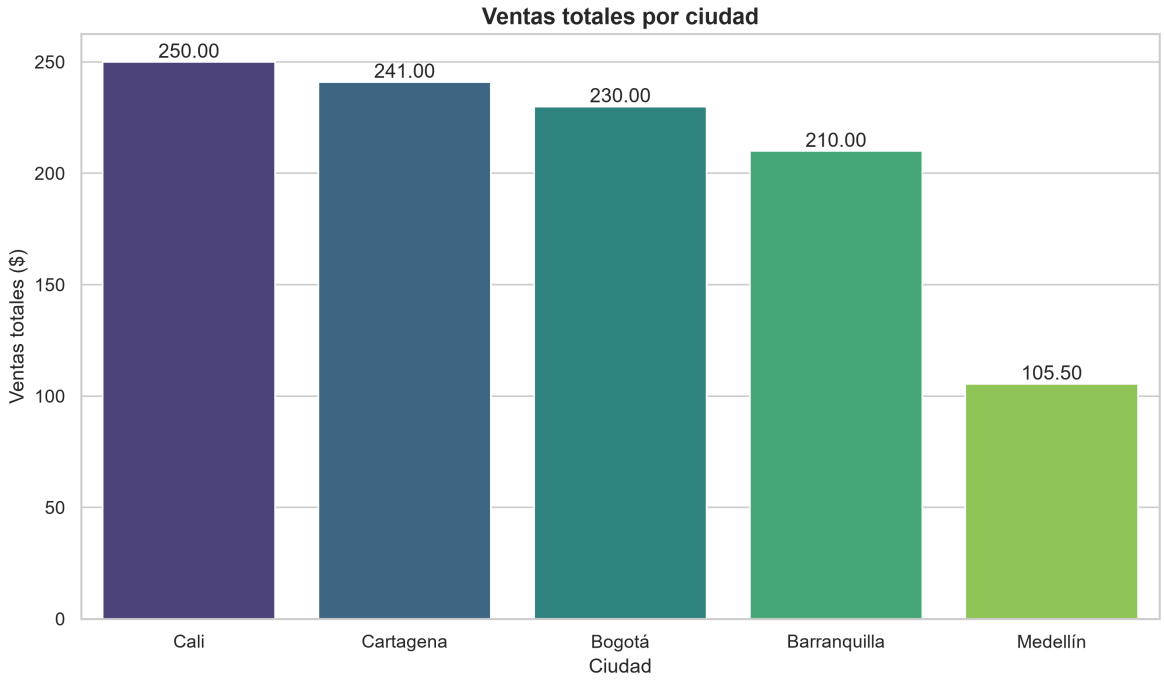
Indicador	Valor
Ventas totales	$1,036.50
Transacciones	20
Unidades vendidas	47
Ticket promedio	$51.83
Ciudad líder	Cali
Categoría líder	Electrónicos
Tienda líder	T003 - Cali

Tabla 1. Indicadores principales del desempeño comercial de SuperMart Colombia.

Análisis Comercial

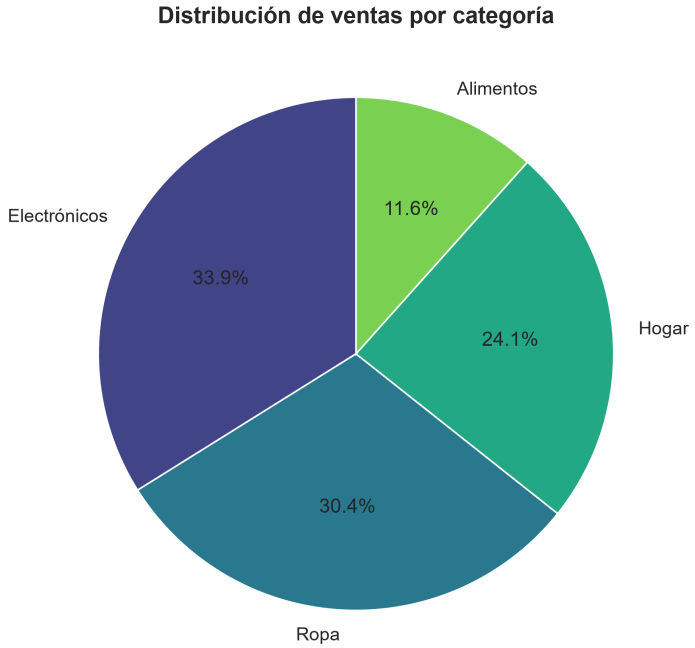
El análisis de los datos permite identificar el comportamiento comercial de la cadena por ciudad, categoría de producto y día de la semana. Las visualizaciones presentadas a continuación fueron generadas automáticamente por el pipeline ETL a partir del dataset transformado y validado.

Figura 1. Ventas totales por ciudad.



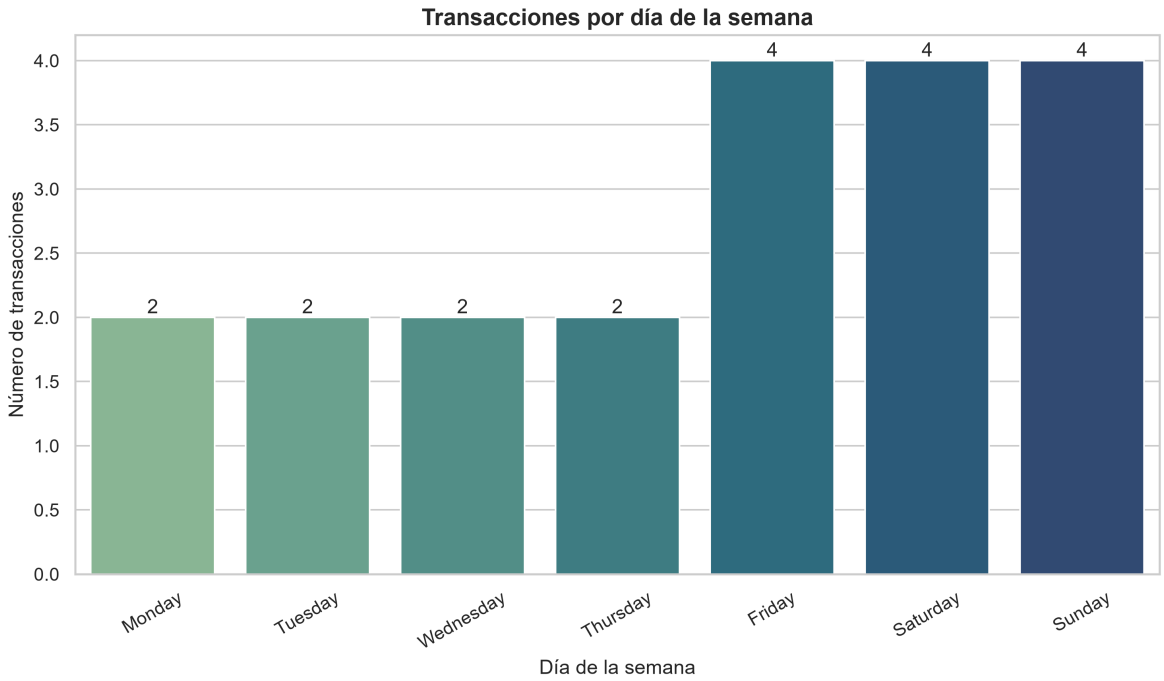
La Figura 1 muestra las ventas totales por ciudad. Este indicador permite identificar los mercados con mayor aporte económico y orientar decisiones relacionadas con inventario, personal comercial y estrategias de expansión.

Figura 2. Distribución de ventas por categoría.



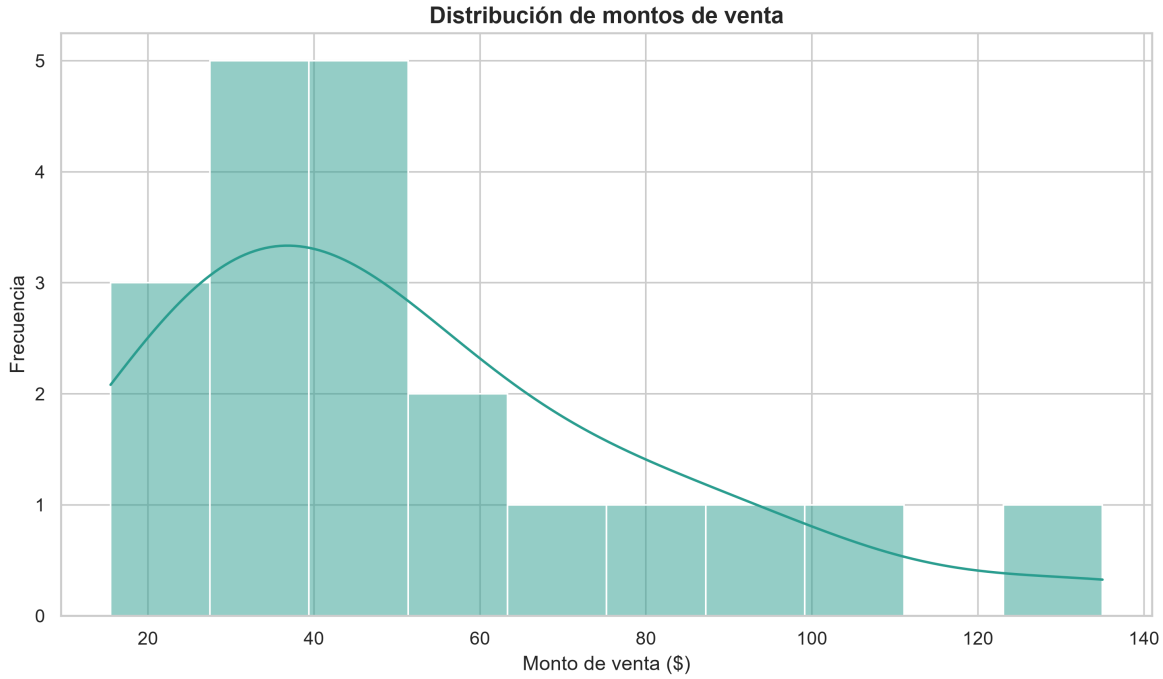
La Figura 2 presenta la participación de cada categoría en las ventas totales. Este análisis facilita la identificación de líneas de producto prioritarias y oportunidades de optimización del portafolio comercial.

Figura 3. Transacciones por día de la semana.



La Figura 3 muestra la cantidad de transacciones registradas por día de la semana. Esta información puede apoyar la planificación de personal, promociones y estrategias de atención al cliente.

Figura 4. Distribución de montos de venta.



La Figura 4 presenta la distribución de los montos de venta. El histograma permite observar la concentración de transacciones por rango de valor y apoyar el diseño de estrategias de precios y promociones.

Resumen por Ciudad y Categoría

Ciudad	Región	Categoría	Transacciones	Ventas totales	Participación (%)
Cali	Valle	Hogar	4	$250.00	24.12%
Cartagena	Bolívar	Ropa	2	$180.00	17.37%
Bogotá	Cundinamarca	Electrónicos	3	$155.00	14.95%
Barranquilla	Atlántico	Electrónicos	2	$120.00	11.58%
Barranquilla	Atlántico	Ropa	1	$90.00	8.68%
Medellín	Antioquia	Alimentos	3	$90.00	8.68%
Cartagena	Bolívar	Electrónicos	2	$61.00	5.89%
Bogotá	Cundinamarca	Ropa	1	$45.00	4.34%
Bogotá	Cundinamarca	Alimentos	1	$30.00	2.89%
Medellín	Antioquia	Electrónicos	1	$15.50	1.50%

Tabla 2. Resumen agregado de ventas por ciudad, región y categoría de producto.

Control de Calidad de Datos

El pipeline implementó controles de calidad orientados a garantizar la confiabilidad del análisis. Se normalizaron fechas inconsistentes, se asignó un identificador estándar a los clientes sin información, se eliminaron órdenes duplicadas y se validaron valores numéricos y relaciones referenciales entre las tablas de ventas, productos y tiendas.

Conclusiones

La implementación del pipeline ETL permitió transformar archivos CSV dispersos en un conjunto de datos estructurado, validado y listo para análisis. La integración de información comercial, geográfica y temporal facilita la identificación de patrones de venta y oportunidades de mejora operativa.

Recomendaciones

• Fortalecer la disponibilidad de inventario en las categorías con mayor participación en ventas.

• Analizar los registros con clientes desconocidos para mejorar la captura de datos en punto de venta.

• Estandarizar los formatos de fecha y los identificadores de cliente desde las fuentes originales.

• Utilizar el Data Mart generado como base para tableros interactivos en Power BI o Looker Studio.

• Priorizar estrategias comerciales en las ciudades y tiendas con mayor desempeño económico.

Referencias

Matplotlib Development Team. (2026). *Matplotlib: Visualization with Python*. https://matplotlib.org/

NumPy Developers. (2026). *NumPy: The fundamental package for scientific computing with Python*. https://numpy.org/

pandas development team. (2026). *pandas: Powerful Python data analysis toolkit*. https://pandas.pydata.org/

ReportLab. (2026). *ReportLab PDF Toolkit user guide*. https://docs.reportlab.com/

Seaborn development team. (2026). *seaborn: Statistical data visualization*. https://seaborn.pydata.org/